

EDA

Какие исходные данные имели - 1001 соединение, 214 признаков. Целевые переменные IC50 (противовирусная активность), CC50 (цитотоксичность), SI (индекс селективности). SI точно равен CC50/IC50. Все признаки кроме целевых числовые характеристики молекул (дескрипторы) и бинарные индикаторы функциональных групп (fr_)

Первым делом мы удалили 3 строки с пропусками, 32 дубликата, 18 константных столбцов (все значения 0). После очистки стало 966 соединений, 195 признаков

После анализа трех целевых переменных выяснили, что все три имеют сильный правый скос. IC50: медиана = 45.2, max = 4128.5. CC50: медиана = 422.2, max = 4539.0. SI: медиана = 3.9, max = 15620.6. Использовали логарифмирование ($\log_{10}$), после которого распределения близки к нормальным, выбросов практически не было

Также перед регрессией посмотрели корреляцию - IC50 и CC50 коррелируют (0.52), связь с признаками умеренная (топ для IC50 - VSA_EState4 0.26, для CC50 - LabuteASA 0.31). Корреляции признаков с SI слабые (макс 0.17), что ожидаемо, тк SI это отношение. Обнаружили 94 пары признаков с взаимной корреляцией >0.95 (потенциальная мультиколлинеарность). Большинство fr_ признаков имеют менее 10 ненулевых значений

Была выбрана следующая методология: для регрессий целевая переменная логарифмировалась, для регрессии SI признаки IC50 и CC50 исключены во избежание утечки данных, признаки масштабированы (StandardScaler), разделение train/test 80/20, random_state=42, для классификации использована стратификация. Подбор гиперпараметров через GridSearchCV с 5-кратной кросс-валидацией. Метрики: R^2 , MAE, RMSE (регрессия), accuracy, precision, recall, F1, ROC-AUC (классификация).

Модели - LinearRegression, Ridge, Lasso, RandomForest, GradientBoosting (регрессия), LogisticRegression, RandomForest, GradientBoosting, SVC (классификация).

Результаты

Для каждой модели будет описана лучшая модель, гиперпараметры подобраны при помощи GridSearch

1. Регрессия IC50

GradientBoosting (learning_rate=0.05, max_depth=3, n_estimators=200). R^2 на тесте 0.42 в log-шкале, 0.31 в исходной. MAE в исходной шкале 175.5, RMSE 370.3. Кросс-валидация: $R^2=0.41\pm0.04$. Самые важные признаки: VSA_EState8, VSA_EState4, BCUT2D_MRLOW. Линейные модели показали R^2 около 0.28, скорее всего зависимость нелинейная

2. Регрессия CC50

Лучшая модель - RandomForest (max_depth=20, n_estimators=200). R^2 на тесте 0.50 в log-шкале, 0.48 в исходной. MAE 267.6, RMSE 457.8. Кросс-валидация: $R^2=0.40\pm0.02$. GradientBoosting показал близкий результат ($R^2=0.46$). Важные признаки: NHOHCount, BCUT2D_MRLOW, BCUT2D_MWLOW. CC50 предсказывается заметно лучше IC50 - корреляции с молекулярной массой (molWT) и размерами молекул (labuteASA) выше

3. Регрессия SI

GradientBoosting (learning_rate=0.05, max_depth=3, n_estimators=100). R^2 на тесте 0.24 в log-шкале, в исходной шкале отрицательный (-0.15). Кросс-валидация: $R^2=0.24\pm0.15$. Важные признаки: VSA_EState6, BCUT2D_LOGPHI, RingCount. Предсказать SI только по структурным признакам не удалось - модель работает хуже, чем предсказание средним значением. Это было ожидаемо, тк SI является отношением IC50 и CC50 и не имеет прямой связи со структурными дескрипторами

4. Классификация IC50 > медианы

LogisticRegression (C=0.1). Accuracy 0.72, ROC-AUC 0.81. RandomForest и SVC показали близкие результаты (ROC-AUC 0.80). Кросс-валидация LR: ROC-AUC=0.72 $\pm$ 0.03. Задача решается не сильно и не слабо, модель способна отделить соединения с высокой и низкой активностью

5. Классификация CC50 > медианы

RandomForest (max_depth=10, n_estimators=100). Accuracy 0.74, ROC-AUC 0.83. Кросс-валидация RF: ROC-AUC=0.83 $\pm$ 0.03. GradientBoosting показал лучший результат на кросс-валидации (0.84). Предсказание цитотоксичности (CC50) работает лучше, чем предсказание активности (ic50), что коррелирует с результатами регрессии

6. Классификация $SI > \text{медианы}$

CVC ($C=1.0$, $\text{kernel}=\text{rbf}$). Accuracy 0.72, ROC-AUC 0.77. Кросс-валидация: ROC-AUC=0.70 $\pm$ 0.02. Качество ниже, чем для IC50 и CC50, что согласуется со слабыми корреляциями признаков с SI

7. Классификация $SI > 8$

RandomForest ($\text{max_depth}=10$, $n_estimators=200$). Accuracy 0.70, ROC-AUC 0.73. Кросс-валидация: ROC-AUC=0.72 $\pm$ 0.02. Дисбаланс классов (35% положительных) не критичен. Модель консервативна: precision выше recall, то есть она чаще пропускает соединения с $SI > 8$, чем дает ложные срабатывания

Выводы

CC50 (цитотоксичность) предсказывается лучше всего как в регрессии ($R^2=0.48$), так и в классификации (ROC-AUC=0.83). Это скорее всего объясняется высокой корреляцией CC50 с базовыми физико-химическими свойствами, например молекулярной массой (MolWt, ExactMolWt), размерами молекулы (LabuteASA), количеством атомов (HeavyAtomCount)

IC50 (противовирусная активность) предсказывается хуже ($R^2=0.31$, ROC-AUC=0.81). Связь IC50 со структурными признаками сложнее и не сводится к простым физико-химическим параметрам

SI (индекс селективности) не удастся надежно предсказать по структурным признакам - регрессия дает отрицательный R^2 , классификация $SI > 8$ имеет ROC-AUC всего 0.73. Судя по всему SI является отношением IC50 и CC50 и зависит от механизмов, не отражаемых в структурных дескрипторах

Для всех задач классификации ансамблевые методы (RandomForest, GradientBoosting) показали лучшие или близкие к лучшим результаты. "Деревянные" модели устойчивы к мультиколлинеарности признаков и не требуют тщательного отбора переменных

Линейные модели (Ridge, Lasso) работают хуже ансамблей, что говорит о существенно нелинейном характере зависимостей между структурой и активностью

Рекомендации для улучшения результатов

Для улучшения предсказания IC50 можно рассмотреть генерацию дополнительных признаков (парные взаимодействия дескрипторов, фармакофорные признаки) или использовать специализированные молекулярные представления (fingerprints)

Для SI использовать двухэтапный подход - предсказывать IC50 и CC50 по отдельности, затем вычислять SI как их отношение. Это должно дать лучший результат, чем прямое предсказание SI по структуре

При расширении датасета собрать больше соединений с высоким SI (>8), так как текущая выборка содержит всего 35% таких примеров, что ограничивает качество классификации